

カスケード分類器の自動車検出における画像データ特性に基づく精度評価

Accuracy evaluation based on image data characteristics in car detection of cascade classifier

20216135 根本 優輝 [関澤研究室]

1 はじめに

近年、交通管理や監視システムの発展に伴い、道路上の車両を正確かつ迅速に識別する技術が求められている。特に、特殊車両（警察車両など）の識別は、交通システムの中で極めて重要な役割を果たすと期待されているが、現代において普及している場面はアメリカやヨーロッパなど一部の主要都市のみと限定的なことが多い。これらの車両は緊急時に優先的な交通処理が求められる一方、一般車両と類似した形状や色を持つ場合が多いため背景の昼夜などの環境条件が認識精度に大きな影響を与える。また認識モデルの精度は、学習に用いる画像データの量や質にも依存する。特に、正例画像（検出対象の画像）が不足している場合、モデル性能が低下すると考えられる。

本研究では、特殊車両の識別を可能とする高精度な分類器を構築するために、基礎段階として認識精度の向上を目標とする。対象をシンプルな一般車両にし、基本的な車両認識技術であるカスケード分類器に着目して、各データ特性の条件がどの程度精度に影響を及ぼすかを多角的に評価する。

2 OpenCV

OpenCV (Open Source Computer Vision Library) は、オープンソース、マルチプラットフォームのライブラリで、元々は Intel 社が開発し、公開したものである。OpenCV には、画像処理やコンピュータビジョン、汎用的な数学処理や機械学習に関するアルゴリズムが多数含まれている^[1]。

3 カスケード分類器

カスケード分類器 (Cascade Classifier) とは、処理が軽くリアルタイム性に優れ、顔検出や車両検出に適しているアルゴリズムである。

分類器は主に、Haar-like 特徴や LBP (Local Binary Patterns) などの特徴量を使用することができ、本研究では Haar-like 特徴量を用いている。この特徴量は複数の局所領域の明暗差から求めた特徴量である^[2]。

分類器の構造としては、図 1 に示すように複数の識別機を組み合わせて構成されており、各段階で物体候補をふるいかけることで正例を精密に検出し、誤検出を減少させて精度を高めることができる。



図 1 カスケード分類器の構造

4 実験準備

本研究におけるカスケード分類器の作成は、以下の手順に従って行う。

1. データセットの準備

2. データセットのリサイズ
3. データセットのリスト化
4. ベクトルファイルの作成
5. カスケード分類器の作成

データセットの準備では、分類器の学習に必要な正例画像（検出対象の自動車）と負例画像（背景や検出対象以外の物体）を用意する。本研究では、基礎段階として認識精度の向上に注力したいため、対象を一般車両とし、kaggle^[3]からデータセットをダウンロードする。

3 段階目のリスト化は用意した正例画像と負例画像のデータ名や絶対パス、画像サイズをテキストファイルに 1 枚ずつ入力する。そのため、リスト化の効率向上を図る目的で 2 段階目に収集したデータセットを 200×150 にリサイズを行う。

4 段階目はリスト化したファイルを図 2 に示すコマンドを用いて、ベクトルファイル化する。最後に図 3 のコマンドを投下することによりカスケード分類器が作成される。

```
C:\Users\Yuki\Desktop>opencv_createsamples.exe -info pos/poslist.txt -vec vec/positive.vec -num 7000 -w 244 -h 244
```

図 2 ベクトルファイルの作成

```
C:\Users\Yuki\Desktop>opencv_traincascade.exe -data cascade -vec vec/positive.vec -bg neg/neglist.txt -numPos 7000 -numNeg 3150
```

図 3 カスケード分類器の作成

5 分類器の精度評価

5.1 評価手法

本研究ではカスケード分類器で学習データのパラメータ特性が精度に対して与える影響を評価するため、以下の 3 つの条件ごとにデータセットから画像を抽出し、分類器を作成した。

1. 学習データの枚数による評価
2. 自動車の色の種類数による評価
3. 背景の昼夜による評価

条件 1 では、正例及び負例の画像枚数を変化させて分類器の検出性能を比較した。想定される結果としては画像の枚数を増加させるにつれて分類器の精度も比例的に高まると考える。具体的な枚数は、下記の表 1 に示すように 5 つの段階ごとに作成する。

表 1 条件 1 の画像枚数の組み合わせ

	1	2	3	4	5
正例画像	1000	3000	5000	7000	10000
負例画像	450	1350	2250	3150	4500

条件 2 では、正例画像における自動車の色の種類を段階的に増やし、分類器の検出性能を比較した。本研究では、白・黒・青の 3 色を初期色とし、赤・黄・緑・茶の順に最大 7 色まで増加させ全 5 種類作成する。正例画像枚数は一律 3000 枚とし、それに伴い負例画像は 1350 枚とする。予測としては色の種類が増える一方、学習データの分散が増加するため、検出できる自動車の多様性は向上するが、特定の色での精度は低下する可能性がある。

条件 3 では、データセットの背景条件を昼間及び夜間に分割し、それぞれの環境下での検出性能を比較した。

画像の枚数は正例画像 7000 枚、負例画像 3150 枚である。昼間は夜間に対して自動車の形状が正確に読み取れるため、昼間の精度が高まると予測される。

以上の条件の基、作成した分類器に 100 枚のテスト画像(車両合計 152 台)を読み込ませ、それぞれ検出数、未検出数、誤検出数の測定を行う。指標は検出率および誤検出数を用いて評価をする。

5.2 評価結果

5.1 章の評価手法の条件で実験を行った結果を、下記の図 4、図 5、図 6 に示す。下記の図は赤色の折れ線グラフが左縦軸の検出率、青色の棒グラフが右縦軸の誤検出数を示している。




図 4 学習データの枚数における精度の変化




図 5 色の種類数に伴う精度の変化




図 6 背景の昼夜に伴う精度の変化

図 4 は条件 1 の結果であり、検出率に関しては学習データの枚数が増加するにつれて向上していることが見てわかる。しかし、7000 枚から 10000 枚にかけての部分では約 1% しか上昇しておらず、大きな変化は認められない。誤検出数は枚数の増加に伴い減少傾向にある。

図 5 は条件 2 の結果であり、色の種類の増加に従って、検出率は 10% 近く上昇している部分があれば、5% 未満の部分もあり上昇幅に差はあるが上昇傾向にある。誤検出数は 6 色の部分のみ増加してしまっている。

図 6 は条件 3 の結果であり、背景が昼間の場合は夜間に比べて検出率は約 10% 高まり、誤検出数は約 2.5% 減少した。

6 考察

条件 1 と 2 から検出率は、正例画像の枚数や色の多様性を増加させることで、全体的に向上した。この傾向は、分類器がより多くの特徴を学習することで、相対的に精度が高まったと考えられる。一方で、誤検出数は条件 1 で減少し、条件 2 で変化がなかったことから負例画像が増加する条件下で著しく減少したと考えられる。

条件 1 での 7000 枚から 10000 枚の範囲で検出率が約 1% しか向上しなかった要因としては、分類器が 7000 枚の時点で一定の特徴を学習した可能性がある。この場合、さらに精度を向上させるためには、車両の外見や背景状況、アングルの多様性を考慮し正例画像のバリエーションを増やすことが必要と考えられる。

条件 2 では、色の種類が 6 色の条件下で誤検出数が増加した。原因は、追加した緑色の自動車が背景の草木などに特徴が埋もれてしまい分類器が自動車と誤認した可能性が挙げられる。改善方法として、背景に緑色が含まれる画像を減らし、建物や砂地など緑色が含まれない画像を増やすなど自動車と背景の類似性を考慮した学習データが考えられる。

条件 3 では、背景が夜間に比べて昼間の時に検出率の向上と誤検出数の低下が確認された。この要因として、昼間は自然光の影響により、車両と背景のコントラストが明瞭となる。よって自動車の特徴を捉えやすく、他のオブジェクトとの区別も明確になると考えられる。対して、夜間は光量不足や人工光源(自動車のライトや街灯)による影響で、車両の色や輪郭などの特徴を学習できていない可能性がある。夜間での識別に対応するために夜間の学習データを用いるが、輝度補正や人工光源の緩和など、適切な前処理が必要と考えられる。

7 まとめと今後の課題

本研究では、特殊車両の識別を可能とする高精度な分類器を作成するためのアプローチとして、対象をシンプルな一般車両にし、基本的な車両認識技術であるカスケード分類器の精度評価を行った。得られた結果から、カスケード分類器の精度向上には、学習データとして最低でも 7000 枚以上の画像を用い、自動車の色を多様化するとともに、夜間のデータセットには適切な前処理を施すことが重要である。また、カスケード分類器は特徴量として単純な明暗差などを用いるため、複雑な条件下での検出に限界が見られた。

今後は、結果と考察から得られた改善方法を基に、天候などのより多様な特徴を持つデータセットの活用や特定の条件に応じた適切な前処理の適用をした場合の評価を行うとともに、深層学習を用いた高度な物体検出手法の併用を検討することで、特殊車両の識別に取り組んでいきたい。

参考文献

- [1] 小枝 正直, 上田 悦子, 中村 恭之, Open CV による画像処理入門, 講談社, p7.
- [2] Haar-like 特徴量を用いたカスケード分類器による前方車両の識別, <https://ohta-lab.inf.gunma-u.ac.jp/ailwiki/index.php?Haar-like>, 2023/05/11.
- [3] kaggle, kaggle/Datasets, <https://www.kaggle.com/datasets>,